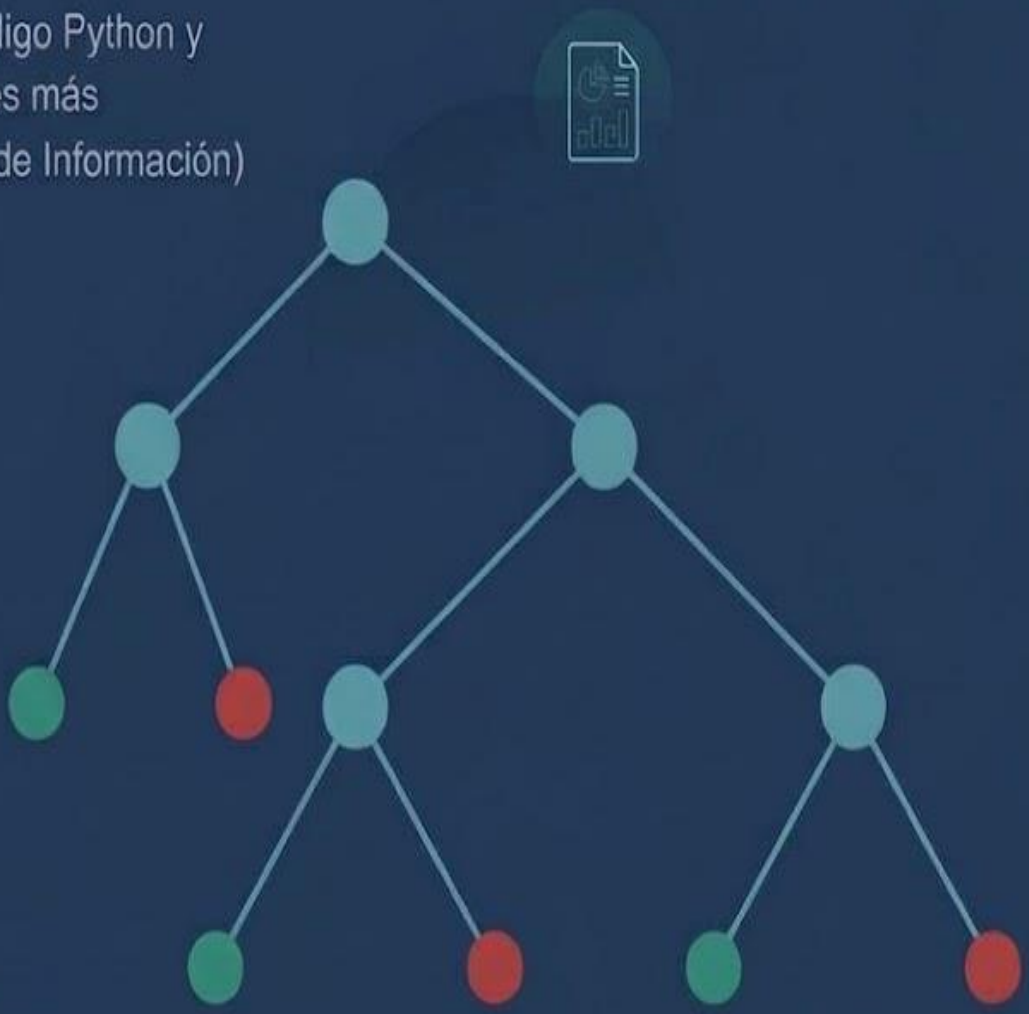
INFORME TÉCNICO | TRABAJO FINAL

Predicción de abandono estudiantil con Árboles de Decisión

Explicación del código Python y análisis de variables más importantes (Gain de Información)



INFORME TÉCNICO: Predicción de Abandono en Estudiantes Terciarios

El Instituto Tecnológico Beltrán desea identificar a los estudiantes con riesgo de abandonar la carrera para implementar estrategias de acompañamiento. Para ello, se ha recopilado un conjunto de datos históricos de estudiantes que incluye las siguientes variables:

- Edad
- Género
- Carrera elegida
- Promedio del primer cuatrimestre
- Cantidad de materias aprobadas en el primer año
- Cantidad de materias desaprobadas
- Asistencia promedio (%)
- Situación laboral (trabaja/no trabaja)
- Distancia desde el domicilio al instituto
- Participación en tutorías o actividades extracurriculares
- Estado final del estudiante (abandonó / continúa)

Objetivo:

Construir un modelo de árbol de decisión que permita predecir si un estudiante abandonará la carrera, en base a los datos de su cursada durante el primer año.

Tareas:

1. Analizar y preparar los datos.
2. Entrenar un árbol de decisión utilizando un conjunto de entrenamiento.
3. Evaluar el modelo con un conjunto de prueba.
4. Interpretar el árbol generado: ¿Qué variables parecen ser más importantes para predecir el abandono?
5. Proponer recomendaciones para la institución basadas en los resultados del modelo.

Resolución.

1. Análisis de los datos.

El Instituto Tecnológico Beltrán busca identificar de manera temprana a aquellos estudiantes terciarios que se encuentran en riesgo de abandonar sus estudios. Para lograr este objetivo, se analizó un conjunto de datos histórico compuesto por distintas variables del primer año de cursada, tales como la edad, el género, el promedio del primer cuatrimestre, la cantidad de materias aprobadas y desaprobadas, la asistencia promedio, la situación laboral, la distancia al instituto y la participación en actividades extracurriculares.

- **Limpieza y Preparación:** Se limpiaron los datos numéricos y se convirtieron las palabras (variables categóricas) en formatos de ceros y unos para que la computadora pudiera entenderlos.
- **Distribución de la Clase Objetivo:** El archivo de entrenamiento tiene 100 registros, donde el 54% de los alumnos abandonó y el 46% continúa, lo cual nos da una base equilibrada para entrenar bien el modelo.

2. Entrenamiento del Árbol de Decisión

Para cumplir con la etapa de modelado, se implementó un **Árbol de Decisión** utilizando la librería scikit-learn

- **División del Conjunto:** Los datos históricos se dividieron utilizando un conjunto de entrenamiento (67%) y un conjunto de prueba (33%) mediante la función train_test_split(test_size=0.33, random_state=42).

- **Criterio de Entropía:** El árbol fue configurado utilizando el criterio de **entropía** (criterion='entropy'), el cual calcula matemáticamente la ganancia de información en cada nodo para determinar cuáles atributos dividen mejor a los estudiantes entre quienes continúan y quienes abandonan la carrera.

3. Evaluación del Modelo

El modelo entrenado fue evaluado utilizando el conjunto de prueba independiente para verificar su capacidad predictiva ante datos nuevos:

- **Precisión (Accuracy):** Mide el porcentaje de predicciones correctas que hizo el modelo al ponerlo a prueba con datos nuevos que no conocía.

- Usar un árbol de decisión facilita ver por qué el modelo marca a un estudiante en riesgo, algo muy útil en la educación para entender el motivo de la alerta.

4. Interpretación del Árbol Generado: ¿Qué variables son más importantes?

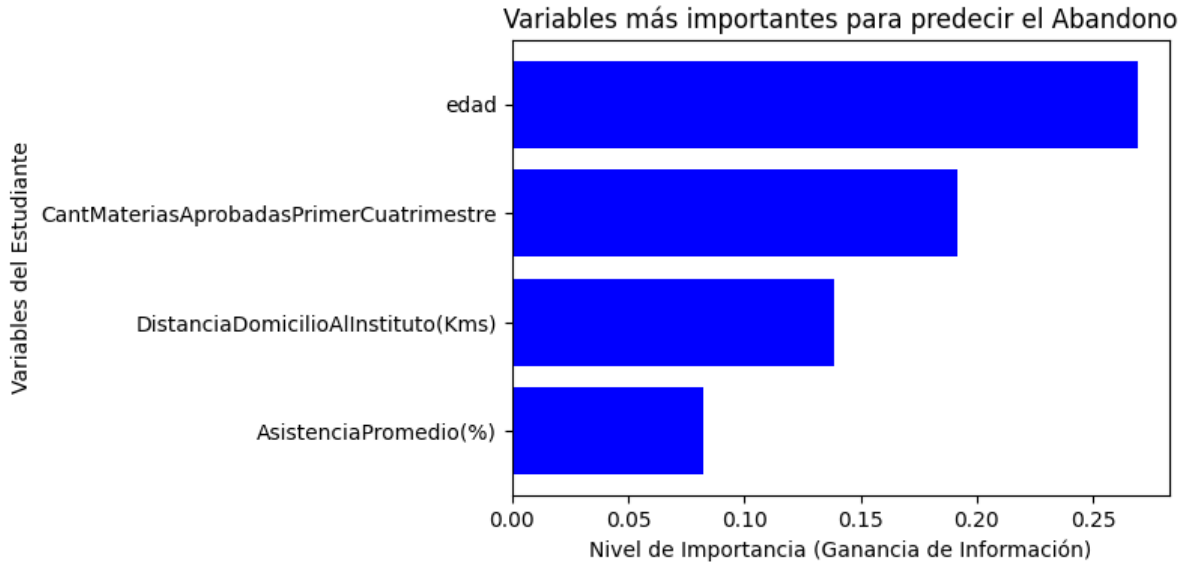
Analizando los resultados arrojados por el modelo, las variables con mayor **Ganancia de Información** que determinan el abandono son:

1. **Edad:** Es la variable con mayor peso predictivo en este análisis, mostrando que la franja etaria influye directamente en la permanencia.

2. **Cantidad de Materias Aprobadas (y Desaprobadas):** El rendimiento académico inicial marca un límite clave entre los estudiantes que continúan y los que abandonan.

3. **Distancia desde el Domicilio al Instituto (Kms):** Los kilómetros de viaje y la logística de traslado actúan como un factor físico importante para sostener la cursada.

A continuación, se muestra un gráfico que resume las cuatro variables que el modelo considera más importantes.



Propuestas para el instituto basadas en el resultado del modelo.

- **Sistema de Alerta Temprana:** Crear un seguimiento automático al terminar el primer cuatrimestre para detectar a tiempo a los alumnos que estén por debajo de los valores críticos marcados por el modelo (como edad, materias aprobadas y distancia).

- **Ayuda con el Traslado:** Evaluar opciones de becas de transporte o facilidades para quienes viven más lejos y tienen dificultades para viajar al instituto, como por ejemplo la virtualidad.

- **Canales de Comunicación y Alertas:** Implementar un canal rápido de contacto institucional (o un bot) para detectar ausencias prolongadas o problemas de asistencia antes de que se conviertan en abandono definitivo.